

Fundamentos de Aprendizagem Automática

2025/2026

Licenciatura em Tecnologias de Informação

Projeto

O objetivo deste projeto é capacitar os alunos na construção de um **fluxo completo de Aprendizagem Automática (End-to-End)**, partindo de um dataset multidimensional que cruza hábitos de vida, comportamento digital e saúde mental de estudantes.

Fase I: Problema e Baseline

Dataset: `student_records_missing.csv`

Nota: Na PL2 usamos o dataset `student_records_full.csv` apenas como exemplo. O projeto deve ser realizado com o dataset `student_records_missing.csv`

1. Definição do Problema e Alvos (Targets)

Nesta etapa, deves atuar como um consultor de dados. Analisa as variáveis disponíveis e define:

- **O Problema:** Que questão queres responder? (Ex: "Prever o risco de exaustão extrema" ou "Estimar a nota final com base no estilo de vida").
- **As Variáveis-Alvo (y):** Selecciona qual (ou quais) das *Target Variables* do dataset melhor responde ao teu problema.
 - Deves definir um cenário de **Regressão**
 - Deves definir um cenário de **Classificação**
- **Stakeholders:** Quem beneficiaria desta previsão? Justifica a escolha.

2. Pipeline de Pré-processamento

- **Implementa um pipeline** para lidar com tipos de dados mistos (numéricos e categóricos).
- **Justifica tecnicamente** a tua escolha de codificação (ex: *One-Hot* vs *Ordinal*) e o método de *scaling* com base na distribuição estatística observada.

3. Treino e Avaliação de Modelos Base

- **Cria uma baseline** utilizando modelos interpretáveis (ex: Regressão Linear, Árvore de Decisão) para as duas tarefas definidas no ponto 1.
- **Define e justifica** uma métrica primária e uma secundária de sucesso para cada modelo.

Fase II: Otimização e Complexidade

1. Engenharia e Seleção de Atributos

- **Reduz a dimensionalidade** do dataset eliminando atributos irrelevantes ou redundantes.
- **Apresenta evidência estatística** (ex: matriz de correlação, *p-values*) ou baseada no modelo para sustentar o descarte de cada variável.

2. Modelos Complexos e Fine-Tuning

- **Treina dois modelos de maior complexidade** (ex: *RandomForest*, *SVM*, *XGBoost* ou *MLP*).
- **Executa um ajuste de hiperparâmetros** sistemático para todos os modelos treinados (Fase I e II).
- **Documenta o "espaço de procura"** (escolha dos parâmetros e estratégia de varrimento de valores) e explica a lógica por trás da seleção final dos parâmetros.

3. Aprendizagem Não Supervisionada (Clustering)

- **Identifica subgrupos latentes** na população estudantil sem utilizar as variáveis-alvo identificadas previamente.
- **Determina o número ideal de clusters** através de heurísticas matemáticas (ex: Elbow-method ou Silhouette Score).
- **Define a "persona"** de cada grupo identificado com base nas suas características médias.

4. Interpretabilidade e Análise Comparativa

- **Aplica uma técnica de explicação agnóstica** (ex: SHAP ou LIME) aos modelos complexos.
- **Seleciona 4 exemplos para explicar**: 1 exemplo de cada (TP, TN, FP, FN).
- Para cada exemplo, **compara a explicação de um modelo *BlackBox*** com a de um modelo interpretável da Fase I, à tua escolha.
- **Cria hipóteses** sobre por que razão os modelos concordam ou discordam sobre a importância de determinados atributos.

Requisitos Obrigatórios

- **Utiliza Validação Cruzada (*Cross-Validation*)** em todas as fases para garantir a robustez dos resultados.
- **Realiza uma Análise de Erro**: inspeciona manualmente as previsões onde o modelo falhou significativamente (outliers) e identifica potenciais causas para a falha.
- **Garante a reprodutibilidade** do código através de comentários claros e organização lógica.

Entregáveis:

1. **Relatório Técnico:** Focado nas justificações das decisões (o "porquê" é mais importante que o "como").
 - a. Formato ACM dupla coluna (máximo 12 páginas) Latex template (usar acmsmall):
<https://www.overleaf.com/latex/templates/acm-conference-proceedings-primary-article-template/wbvngbjbwpc>
2. **Código:** Jupyter Notebook organizado e limpo.

Obrigatório: Identificar o Relatório e Notebook, com nomes dos autores, números de aluno e número de grupo.